



**Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

**Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»**

**Отчет по лабораторной работе №6
«Анализ и прогнозирование временного ряда»
по дисциплине «Технологии машинного обучения»**

Выполнил:
студент группы ИУ5Ц-84Б
Перовошиков Н.Д.
подпись, дата

Проверил:
к.т.н., доц., Гапанюк Ю.Е.
подпись, дата

2024 г.

СОДЕРЖАНИЕ ОТЧЕТА

1. Цель лабораторной работы.....	3
2. Задание	3
3. Основные характеристики датасета.....	3
4. Листинг	4
5. Вывод.....	28

1. Цель лабораторной работы

Изучение основных методов анализа и прогнозирование временных рядов.

2. Задание

- 1) Выберите набор данных (датасет) для решения задачи прогнозирования временного ряда.
- 2) Визуализируйте временной ряд и его основные характеристики.
- 3) Разделите временной ряд на обучающую и тестовую выборку.
- 4) Произведите прогнозирование временного ряда с использованием как минимум двух методов.
- 5) Визуализируйте тестовую выборку и каждый из прогнозов.
- 6) Оцените качество прогноза в каждом случае с помощью метрик.

3. Основные характеристики датасета

Название датасета: Набор данных о временных рядах акций DJIA 30

Ссылка: https://www.kaggle.com/datasets/szrlee/stock-time-series-20050101-to-20171231?select=GOOGL_2006-01-01_to_2018-01-01.csv

О датасетах

Данные фондового рынка могут быть интересны для анализа, и в качестве дополнительного стимула надежные прогностические модели могут принести большую финансовую отдачу. Количество финансовых данных в Интернете, по-видимому, бесконечно. Получить большой и хорошо структурированный набор данных по широкому кругу компаний может быть непросто. Здесь представлен набор данных с историческими ценами акций (за последние 12 лет) для 29 из 30 компаний DJIA (исключая 'V', поскольку в нем нет полных данных за 12 лет).

Структура данных

Здесь указаны 5 параметров:

open - цена акций в момент открытия рынка

high - самая высокая цена акций, достигнутая в день

low - самая низкая цена акций, достигнутая в день

close - цена акций в момент закрытия рынка

volume - количество проданных акций

4. Листинг

4.1.Изучение данных

4.1.1. Обучающий датасет

```
display(df_train.info())
display(df_train.describe())
display(df_train.head())
```

```
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 3019 entries, 2006-01-03 to 2017-12-29
Data columns (total 6 columns):
 #   Column  Non-Null Count  Dtype  
---  --
 0   open    3019 non-null    float64
 1   high    3019 non-null    float64
 2   low     3019 non-null    float64
 3   close   3019 non-null    float64
 4   volume  3019 non-null    int64  
 5   name     3019 non-null    object  
dtypes: float64(4), int64(1), object(1)
memory usage: 165.1+ KB
None
```

	open	high	low	close	volume
count	3019.000000	3019.000000	3019.000000	3019.000000	3.019000e+03
mean	428.200802	431.835618	424.130275	428.044001	3.551504e+06
std	236.320026	237.514087	234.923747	236.343238	3.038599e+06
min	131.390000	134.820000	123.770000	128.850000	5.211410e+05
25%	247.775000	250.190000	244.035000	247.605000	1.760854e+06
50%	310.480000	312.810000	307.790000	310.080000	2.517630e+06
75%	572.140000	575.975000	565.900000	570.770000	4.242182e+06
max	1083.020000	1086.490000	1072.270000	1085.090000	4.118289e+07

	open	high	low	close	volume	name
date						
2006-01-03	211.47	218.05	209.32	217.83	13137450	GOOGL
2006-01-04	222.17	224.70	220.09	222.84	15292353	GOOGL
2006-01-05	223.22	226.00	220.97	225.85	10815661	GOOGL
2006-01-06	228.66	235.49	226.85	233.06	17759521	GOOGL
2006-01-09	233.44	236.94	230.70	233.68	12795837	GOOGL

4.1.2. Тестовый датасет

```
display(df_test.info())
display(df_test.describe())
display(df_test.head())

<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 3019 entries, 2006-01-03 to 2017-12-29
Data columns (total 6 columns):
#   Column  Non-Null Count  Dtype
---  ------  -
0    open    3019 non-null      float64
1    high    3019 non-null      float64
2    low     3019 non-null      float64
3    close   3019 non-null      float64
4    volume  3019 non-null      int64
5    name    3019 non-null      object
dtypes: float64(4), int64(1), object(1)
memory usage: 165.1+ KB
None
```

	open	high	low	close	volume
count	3019.000000	3019.000000	3019.000000	3019.000000	3.019000e+03
mean	428.200802	431.835618	424.130275	428.044001	3.551504e+06
std	236.320026	237.514087	234.923747	236.343238	3.038599e+06
min	131.390000	134.820000	123.770000	128.850000	5.211410e+05
25%	247.775000	250.190000	244.035000	247.605000	1.760854e+06
50%	310.480000	312.810000	307.790000	310.080000	2.517630e+06
75%	572.140000	575.975000	565.900000	570.770000	4.242182e+06
max	1083.020000	1086.490000	1072.270000	1085.090000	4.118289e+07

	open	high	low	close	volume	name
date						
2006-01-03	211.47	218.05	209.32	217.83	13137450	GOOGL
2006-01-04	222.17	224.70	220.09	222.84	15292353	GOOGL
2006-01-05	223.22	226.00	220.97	225.85	10815661	GOOGL
2006-01-06	228.66	235.49	226.85	233.06	17759521	GOOGL
2006-01-09	233.44	236.94	230.70	233.68	12795837	GOOGL

4.2.Предобработка данных

4.2.1. Пропуски

```
df_train.isna().sum()
```

```
open      0
high      0
low       0
close     0
volume    0
name      0
dtype: int64
```

```
df_test.isna().sum()
```

```
open      0
high      0
low       0
close     0
volume    0
name      0
dtype: int64
```

Пропусков нет, это говорится о том, что датасет был сделан хорошо.

4.2.2. Дубликаты

```
df_train.duplicated().sum()
```

```
0
```

```
df_test.duplicated().sum()
```

```
0
```

Дубликатов нет, это говорится о том, что датасет был сделан хорошо.

4.2.3. Удаление не числового типа

У нас есть значение в столбце паме, мы его удалим, т.к. чтобы не было

конфликта в обучающей и тестовой выборке.

```
# Для df_train
df_train.drop(columns=['name'], inplace=True)
# Для df_test
df_test.drop(columns=['name'], inplace=True)
```

4.2.4. Добавление среднего значения

```
# Добавляем новый столбец 'average_price' средняя цена в момент открытия и закрытия акции
# Для df_train
df_train['average_price'] = (df_train['open'] + df_train['close']) / 2

# Для df_test
df_test['average_price'] = (df_test['open'] + df_test['close']) / 2
```

```
# Проверим
display(df_train.head())
display(df_test.head())
```

	open	high	low	close	volume	average_price
date						
2006-01-03	211.47	218.05	209.32	217.83	13137450	214.650
2006-01-04	222.17	224.70	220.09	222.84	15292353	222.505
2006-01-05	223.22	226.00	220.97	225.85	10815661	224.535
2006-01-06	228.66	235.49	226.85	233.06	17759521	230.860
2006-01-09	233.44	236.94	230.70	233.68	12795837	233.560

	open	high	low	close	volume	average_price
date						
2006-01-03	211.47	218.05	209.32	217.83	13137450	214.650
2006-01-04	222.17	224.70	220.09	222.84	15292353	222.505
2006-01-05	223.22	226.00	220.97	225.85	10815661	224.535
2006-01-06	228.66	235.49	226.85	233.06	17759521	230.860
2006-01-09	233.44	236.94	230.70	233.68	12795837	233.560

4.3. Анализ графики временного ряда


4.3.1. Цена акций в момент открытия рынка

```
# Рассмотрим график и узнаем о нем
fig, ax_year = plt.subplots(figsize=(25,10))

ax_year.plot(df_train.index, df_train['open'])
ax_year.grid()

plt.title('Цена акции на момент открытия рынка по промежутке времени')
ax_year.set_xlabel('Временной ряд')
ax_year.set_ylabel('Цена в момент открытия рынка')
ax_year.legend(['open'], fontsize='larger')

plt.show()
```



Цена акций на момент открытия рынка увеличивается с каждым годом.


4.3.2. Самая высокая цена акций, достигнутая в день

```
# Рассмотрим график и узнаем о нем
fig, ax_year = plt.subplots(figsize=(25,10))

ax_year.plot(df_train.index, df_train['high'])
ax_year.grid()

plt.title('Самая высокая цена, достигнутая за день по промежутке времени')
ax_year.set_xlabel('Временной ряд')
ax_year.set_ylabel('Самая высокая цена, достигнутая за день')
ax_year.legend(['high'], fontsize='larger')

plt.show()
```



Самая высокая цена акций, достигнутая в день, увеличивается с каждым годом.


4.3.3. Самая низкая цена акций, достигнутая в день

```
# Рассмотрим график и узнаем о нем
fig, ax_year = plt.subplots(figsize=(25,10))

ax_year.plot(df_train.index, df_train['low'])
ax_year.grid()

plt.title('Самая низкая цена, достигнутая за день по промежутке времени')
ax_year.set_xlabel('Временной ряд')
ax_year.set_ylabel('Самая низкая цена, достигнутая за день')
ax_year.legend(['low'], fontsize='larger')

plt.show()
```



Самая низкая цена акций, достигнутая в день, увеличивается с каждым годом.


4.3.4. Цена акций в момент закрытия рынка

```
# Рассмотрим график и узнаем о нем
fig, ax_year = plt.subplots(figsize=(25,10))

ax_year.plot(df_train.index, df_train['close'])
ax_year.grid()

plt.title('Цена акции на момент закрытия по промежутке времени')
ax_year.set_xlabel('Временной ряд')
ax_year.set_ylabel('Цена акции на момент закрытия')
ax_year.legend(['close'], fontsize='larger')

plt.show()
```



Цена акций на момент закрытия рынка увеличивается с каждым годом.


4.3.5. Количество проданных акций

```
# Рассмотрим график и узнаем о нем
fig, ax_year = plt.subplots(figsize=(25,10))

ax_year.plot(df_train.index, df_train['volume'])
ax_year.grid()

plt.title('Количество проданных акций по промежутке времени')
ax_year.set_xlabel('Временной ряд')
ax_year.set_ylabel('Количество проданных акций')
ax_year.legend(['volume'], fontsize='larger')

plt.show()
```



Количество проданных акций уменьшается с каждым годом.


4.3.6. Средняя цена акций в момент открытия и закрытия рынка

```
# Рассмотрим график и узнаем о нем
fig, ax_year = plt.subplots(figsize=(25,10))

ax_year.plot(df_train.index, df_train['average_price'])
ax_year.grid()

plt.title('Средняя цена в момент открытия и закрытия акций по промежутке времени')
ax_year.set_xlabel('Временной ряд')
ax_year.set_ylabel('Количество проданных акций')
ax_year.legend(['average_price'], fontsize='larger')

plt.show()
```



Средняя цена акций в момент открытия и закрытия рынка увеличивается с каждым годом.

4.3.7. График со скользящими среднее

```
df_train_temp = df_train[['average_price']]
df_test_temp = df_test[['average_price']]


# Добавим скользящие среднее
df_train_temp['rolling_average_price'] = df_train_temp.rolling(10).mean()
df_test_temp['rolling_average_price'] = df_test_temp.rolling(10).mean()
```

```
# И снова рассмотрим график и узнаем о нем
fig, ax_year = plt.subplots(figsize=(25,10))

ax_year.plot(df_train_temp.index, df_train_temp)
ax_year.grid()

plt.title('График временного ряда')
ax_year.set_xlabel('Временной ряд')
ax_year.set_ylabel('Частота')
ax_year.legend(df_train_temp, fontsize='larger')

plt.show()
```




Здесь получилось неудобной и неинформативной, рассмотрим определенный промежуток времени.

```
fig, ax_month = plt.subplots(figsize=(25,10))

# За 2 месяца
ax_month.plot(df_train_temp['2009-09-01':'2009-11-01'].index, df_train_temp['2009-09-01':'2009-11-01'])
ax_month.grid()

plt.title('График временного ряда за 2 месяца')
ax_month.set_xlabel('Временной ряд')
ax_month.set_ylabel('Средняя цена в момент открытия и закрытия акции')
ax_month.legend(df_train_temp, fontsize='larger')

plt.show()
```



Рост средней цены акции за осень 2009 года

4.3.8. Исследование стационарных рядов


```
df_train_temp['std'] = df_train_temp['average_price'].rolling(15).std()
df_test_temp['std'] = df_test_temp['average_price'].rolling(15).std()
```

```
# И снова рассмотрим график и узнаем о нем
fig, ax_month = plt.subplots(figsize=(25,10))
```

```
# За 2 месяца
ax_month.plot(df_train_temp['2009-09-01':'2009-11-01'].index, df_train_temp['2009-09-01':'2009-11-01'])
ax_month.grid()
```

```
plt.title('График временного ряда за 2 месяца')
ax_month.set_xlabel('Временной ряд')
ax_month.set_ylabel('Средняя цена в момент открытия и закрытия акции')
ax_month.legend(df_train_temp, fontsize='larger')
```

```
plt.show()
```




```
# И снова рассмотрим график и узнаем о нем
fig, ax_month = plt.subplots(figsize=(25,10))
```

```
# За месяца
ax_month.plot(df_train_temp.index, df_train_temp)
ax_month.grid()
```

```
plt.title('График временного ряда за весь промежуток')
ax_month.set_xlabel('Временной ряд')
ax_month.set_ylabel('Средняя цена в момент открытия и закрытия акции')
ax_month.legend(df_train_temp, fontsize='larger')
```

```
plt.show()
```



Примечание:

Стохастический процесс - это случайная величина, у которой со временем меняется её распределение. У этой величины есть среднее и дисперсия, которые тоже меняются. Стохастический процесс стационарный (англ. stationary stochastic process), если его распределение со временем не меняется. Например, к такому процессу относятся периодические колебания значений.

Если распределение меняется, то процесс называется нестационарным.

Насчет временного ряда, его можно назвать стационарным или нет - нельзя, пока не проверим на тренды, сезонность и остаток декомпозиции.

4.3.8.1. Тренды и сезонность

4.3.8.1.1. Тренды


```
# если период сезонности составляет 12 месяцев
decomposed = seasonal_decompose(df_train_temp['average_price'], period=12)

# Тренд
fig, ax_decomposed = plt.subplots(figsize=(20,10))

ax_decomposed.plot(decomposed.trend.index, decomposed.trend)
ax_decomposed.grid()

plt.title('Тренд')
ax_decomposed.set_xlabel('Временной ряд')
ax_decomposed.set_ylabel('Средняя цена в момент открытия и закрытия акций')
ax_decomposed.legend(df_train_temp, fontsize='larger')

plt.show()
```



Тренд в последнее время увеличивается.

4.3.8.1.2. Сезонность

Рассмотрим сезонность в коротком промежутке, т.к. на длинном он не

приносит мало полезных информации. Рассмотрим за неделю.

```
fig, ax_decomposed = plt.subplots(figsize=(20,10))

ax_decomposed.plot(decomposed.seasonal['2009-09-01':'2009-11-01'].index, decomposed.seasonal['2009-09-01':'2009-11-01'])
ax_decomposed.grid()

plt.title('Сезонность')
ax_decomposed.set_xlabel('Временной ряд')
ax_decomposed.set_ylabel('Частота')
ax_decomposed.legend(df_train_temp, fontsize='larger')

plt.show()
```




График представляет собой циклическим способом (выглядит почти как кардиограмма сердца). Можно предполагать, что этот временной ряд стационарен, однако все равно лучше убедиться математическим способом, который приведен ниже.


4.3.8.1.3. Остаток декомпозиции

```
# Остаток декомпозиции
fig, ax_decomposed = plt.subplots(figsize=(20,10))

ax_decomposed.plot(decomposed.resid.index, decomposed.resid)
ax_decomposed.grid()

plt.title('Остаток декомпозиции')
ax_decomposed.set_xlabel('Временной ряд')
ax_decomposed.set_ylabel('Частота')
ax_decomposed.legend(df_train_temp, fontsize='larger')

plt.show()
```



По поводу остатка декомпозиции нужно провести исследование отдельно, причем детально, поскольку декомпозиции остатков интерпретировать сложнее, чем сезонность и тренды - в идеале, график остатков должен содержать только шум без систематических компонентов.

Если остатки систематически распределены (например, отрицательны в первой части ряда и примерно равны нулю во второй) или включают некоторую периодическую компоненту, то это свидетельствует о неадекватности модели. Анализ остатков чрезвычайно важен и необходим при анализе временных рядов. Процедура оценивания предполагает, что остатки не коррелированы и нормально распределены.

4.3.8.2. Проверка на дисперсию математическим способом

Можно проверить дисперсию, применяя теста Андерсона-Дарлинга.

```
# x - временной ряд
# dist='norm' - ожидаемое распределение (нормальное)
result = anderson(x=df_train_temp['average_price'], dist='norm')

# Статистика теста
test_statistic = result.statistic

# Критические значения для разных уровней значимости (1%, 5%, 10%)
critical_values = result.critical_values

# Если статистика теста больше критического значения для выбранного уровня значимости, то дисперсия не является постоянной
if test_statistic > critical_values[2]:
    print("Дисперсия не является постоянной")
else:
    print("Дисперсия является постоянной")
```

Дисперсия не является постоянной

Этот промежуток времени, т.е. с 2006 до конца, является нестационарным, т.к. присутствует тренд, который стремится

увеличиваться. А также дисперсия не является постоянной. Проверим на стационарность математическим способом.

4.3.8.3. Проверка на стационарность математическим способом

4.3.8.3.1. Тест Дики-Фуллера

```
print('*100')
# тест Дики-Фуллера на стационарность
print('Тест Дики-Фуллера на стационарность')
print('*100')
result = adfuller(df_train_temp['average_price'])

print('ADF Статистка: %f' % result[0])
print('p-value: %f' % result[1])
print('Critical Values:')
for key, value in result[4].items():
    print('\t%s: %.3f' % (key, value))

print('*100')

if(result[1] < 0.05):
    print('Принимаем альтернативную гипотезу. Временной ряд стационарен')
else:
    print('Отвергаем альтернативную гипотезу. Временной ряд не стационарен')
print('*100')
```

```
=====
Тест Дики-Фуллера на стационарность
=====
ADF Статистка: 1.219026
p-value: 0.996115
Critical Values:
1%: -3.433
5%: -2.863
10%: -2.567
=====
Отвергаем альтернативную гипотезу. Временной ряд не стационарен
=====
```

4.3.8.3.2. Тест KPSS – Квятковский-Филлипс-Шмидт-Шина Дики-Фуллер

```
print('*100')
# KPSS-тест на стационарность
# KPSS - Квятковского-Филлипса-Шмидта-Шина
print('KPSS-тест на стационарность')
print('*100')
result = kpss(df_train_temp['average_price'])
print('KPSS Статистка: %f' % result[0])
print('p-value: %f' % result[1])
print('Critical Values:')
for key, value in result[3].items():
    print('\t%s: %.3f' % (key, value))

print('*100')
#### Тест Дики-Фуллера
if(result[1] < 0.05):
    print('Принимаем альтернативную гипотезу. Временной ряд стационарен')
else:
    print('Отвергаем альтернативную гипотезу. Временной ряд не стационарен')
print('*100')
```

```
=====
KPSS-тест на стационарность
=====
KPSS Статистка: 7.821837
p-value: 0.010000
Critical Values:
10%: 0.347
5%: 0.463
2.5%: 0.574
1%: 0.739
=====
Принимаем альтернативную гипотезу. Временной ряд стационарен
=====
```

ADF-тест не обнаруживает статистически значимого доказательства о стационарности временного ряда, в то время как KPSS-тест отвергает нулевую гипотезу о стационарности. Это противоречие может

свидетельствовать о том, что ряд не является полностью стационарным, но также не является сильно нестационарным. Возможно, в ряде присутствует некоторая форма нестационарности, которая может быть устранена с помощью дополнительной обработки данных или моделирования.

4.3.9. Промежуточный вывод

По графику видно, что с каждым годом цена акций увеличивается, по тренду это доказано.

Также на математическом языке были доказаны следующие тесты:

- На дисперсию
- На стационарность
- Тест Дики-Фуллера
- Тест KPSS - Квятковский-Филлипс-Шмидт-Шина Дики-Фуллер

Тест на дисперсию говорит, что не является постоянной, т.е. здесь получилось, что статистика теста больше критического значения для выбранного уровня значимости

А тесты на стационарность дали разные результаты - в одном отсутствует стационарность, а в другом имеется стационарность. Исходя из этих факторов, различные результаты тестов могут быть объяснены разными свойствами и характеристиками временного ряда. Важно учитывать контекст и особенности данных при интерпретации результатов тестов на стационарность.

4.4. Обучение и тестирование

```
# Сохраним результаты машинного обучения
results = pd.DataFrame()

# Счетчик для нумерации моделей
count_model = 0

# Создадим признаки, чтобы правильно обучить модель
def make_features(data, column, max_lag, rolling_mean_size):
    data['hour'] = data.index.hour
    data['day'] = data.index.day
    data['dayofweek'] = data.index.dayofweek

    for lag in range(1, max_lag + 1):
        data['lag_{}'.format(lag)] = data[column].shift(lag)

    data['rolling_mean'] = data[column].shift().rolling(rolling_mean_size).mean()
```

4.4.1. Деление на обучающий и тестовой выборки

Имеется 2 датасета: обучающий и тестовый.

```
# Сделаем копию, чтобы было удобно организовать несколько подборок
df_copy_train = df_train.copy()
df_copy_test = df_train.copy()
```

```
# Функция для создания новых признаков
make_features(df_copy_train, 'average_price', 48, 96)
make_features(df_copy_test, 'average_price', 48, 96)
```

```
features_train = df_copy_train.drop(['average_price'], axis=1)
target_train = df_copy_train['average_price']

features_test = df_copy_test.drop(['average_price'], axis=1)
target_test = df_copy_test['average_price']
```

```
# Проверим
print(features_train.shape)
print(features_test.shape)

(3019, 57)
(3019, 57)
```

```
# Проверим
display(features_train.head())
display(features_test.head())
```

	open	high	low	close	volume	hour	day	dayofweek	lag_1	lag_2	...	lag_40	lag_41	lag_42	lag_43	lag_44	lag_45	lag_46	lag_47	lag_48	r
date																					
2006-01-03	211.47	218.05	209.32	217.83	13137450	0	3	1	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-04	222.17	224.70	220.09	222.84	15292353	0	4	2	214.650	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-05	223.22	226.00	220.97	225.85	10815661	0	5	3	222.505	214.650	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-06	228.66	235.49	226.85	233.06	17759521	0	6	4	224.535	222.505	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-09	233.44	236.94	230.70	233.68	12795837	0	9	0	230.860	224.535	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

5 rows × 57 columns

	open	high	low	close	volume	hour	day	dayofweek	lag_1	lag_2	...	lag_40	lag_41	lag_42	lag_43	lag_44	lag_45	lag_46	lag_47	lag_48	r
date																					
2006-01-03	211.47	218.05	209.32	217.83	13137450	0	3	1	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-04	222.17	224.70	220.09	222.84	15292353	0	4	2	214.650	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-05	223.22	226.00	220.97	225.85	10815661	0	5	3	222.505	214.650	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-06	228.66	235.49	226.85	233.06	17759521	0	6	4	224.535	222.505	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2006-01-09	233.44	236.94	230.70	233.68	12795837	0	9	0	230.860	224.535	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

5 rows × 57 columns

```
# Проверим
display(features_train.tail())
display(features_test.tail())
```

	open	high	low	close	volume	hour	day	dayofweek	lag_1	lag_2	...	lag_40	lag_41	lag_42	lag_43	lag_44	lag_45	lag_46
date																		
2017-12-22	1070.00	1071.72	1067.64	1068.86	889446	0	22	4	1073.120	1077.240	...	994.945	988.865	987.495	995.360	1006.060	1003.295	1011.895
2017-12-26	1068.64	1068.86	1058.64	1065.85	918767	0	26	1	1069.430	1073.120	...	1032.330	994.945	988.865	987.495	995.360	1006.060	1003.295
2017-12-27	1066.60	1068.27	1058.38	1060.20	1116203	0	27	2	1067.245	1069.430	...	1031.145	1032.330	994.945	988.865	987.495	995.360	1006.060
2017-12-28	1062.25	1064.84	1053.38	1055.95	994249	0	28	3	1063.400	1067.245	...	1033.020	1031.145	1032.330	994.945	988.865	987.495	995.360
2017-12-29	1055.49	1058.05	1052.70	1053.40	1180340	0	29	4	1059.100	1063.400	...	1039.460	1033.020	1031.145	1032.330	994.945	988.865	987.495

5 rows × 57 columns

	open	high	low	close	volume	hour	day	dayofweek	lag_1	lag_2	...	lag_40	lag_41	lag_42	lag_43	lag_44	lag_45	lag_46
date																		
2017-12-22	1070.00	1071.72	1067.64	1068.86	889446	0	22	4	1073.120	1077.240	...	994.945	988.865	987.495	995.360	1006.060	1003.295	1011.895
2017-12-26	1068.64	1068.86	1058.64	1065.85	918767	0	26	1	1069.430	1073.120	...	1032.330	994.945	988.865	987.495	995.360	1006.060	1003.295
2017-12-27	1066.60	1068.27	1058.38	1060.20	1116203	0	27	2	1067.245	1069.430	...	1031.145	1032.330	994.945	988.865	987.495	995.360	1006.060
2017-12-28	1062.25	1064.84	1053.38	1055.95	994249	0	28	3	1063.400	1067.245	...	1033.020	1031.145	1032.330	994.945	988.865	987.495	995.360
2017-12-29	1055.49	1058.05	1052.70	1053.40	1180340	0	29	4	1059.100	1063.400	...	1039.460	1033.020	1031.145	1032.330	994.945	988.865	987.495

5 rows × 57 columns

```
# Проверим на пропущенные значения
print('-'*100)
print('features_train')
display(features_train.isna().sum())
print('-'*100)
print('features_test')
display(features_test.isna().sum())
print('-'*100)
```

```
-----
features_train
open          0
high          0
low           0
close         0
volume        0
hour          0
day           0
dayofweek     0
lag_1         1
lag_2         2
lag_3         3
lag_4         4
lag_5         5
lag_6         6
lag_7         7
lag_8         8
```

Есть пропущенных значений, заполним их значением 0.

```
features_train = features_train.fillna(0)
features_test = features_test.fillna(0)
```

```
# Проверим на пропущенные значения
print('-'*100)
print('features_train')
display(features_train.isna().sum())
print('-'*100)
print('features_test')
display(features_test.isna().sum())
print('-'*100)
```

```
features_train
```

```
open      0
high      0
low       0
close     0
volume    0
hour      0
day       0
dayofweek 0
lag_1     0
lag_2     0
lag_3     0
lag_4     0
lag_5     0
lag_6     0
lag_7     0
lag_8     0
```

Обучение моделей с применением TimeSeriesSplit.

Мы обучаем модель TimeSeriesSplit, у которой по индексу стоит временной ряд. А чтобы они не пересекались, это поможет инструмент TimeSeriesSplit. Как работает, рассмотрим ниже.

```
# Не будем создавать по-умолчанию, где n_splits=5, а установим n_splits=10
tscv = TimeSeriesSplit(10)
print(tscv)
```

```
TimeSeriesSplit(gap=0, max_train_size=None, n_splits=10, test_size=None)
```

```
for i, (train_index, test_index) in enumerate(tscv.split(features_train)):
    print(f"Fold {i}:")
    print('-'*100)
    print(f"  Train: index={train_index}")
    print('-'*100)
    print(f"  Test:  index={test_index}")
```

```
Fold 0:
```

```
=====
Train: index=[ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17
18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35
36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53
54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71
72 73 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89
90 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105 106 107
108 109 110 111 112 113 114 115 116 117 118 119 120 121 122 123 124 125
126 127 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143
144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160 161
162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179
180 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197
198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215
216 217 218 219 220 221 222 223 224 225 226 227 228 229 230 231 232 233
234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 250 251
252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268 269
270 271 272 273 274 275 276 277 278]
```

Как и видим, что разделен на несколько промежутков времени, по 10 блоков времени.

4.4.2. Машинное обучение

4.4.2.1. LinearRegression

```
# Устанавливаем нужные параметры
parameters = {}

# Инициализируем модель
model = GridSearchCV(LinearRegression(), param_grid = parameters, cv = tscv, scoring = 'neg_root_mean_squared_error')
```

```
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)

# Узнаем RMSE обучающей выборки
RMSE_TRAIN = -model.best_score_
print('RMSE TRAIN:', RMSE_TRAIN)
print('TIME TRAIN [s]:', round(model.refit_time_, 3))

RMSE TRAIN: 3.822832006532797e-10
TIME TRAIN [s]: 0.023
CPU times: total: 15.6 ms
Wall time: 287 ms
```

Проверка на тестовой выборки

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборке
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

# Узнаем RMSE
RMSE_TEST = mean_squared_error(target_test, predictions, squared=False)
print('RMSE TEST:', RMSE_TEST)
print('Предсказание:', predictions.mean())

RMSE TEST: 9.217950802816517e-10
Предсказание: 428.12240145743624
CPU times: total: 0 ns
Wall time: 5.02 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': 'LinearRegression',
    'RMSE TRAIN': RMSE_TRAIN,
    'RMSE TEST': RMSE_TEST,
    'PREDICTIONS': predictions,
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.4.2.2. DecisionTreeRegressor

```
# Матрица гиперпараметров
parameters = {'max_depth': range(1, 201, 10), 'min_samples_leaf': [1, 0.5, 2]}

# Инициализируем модель с параметрами
model = GridSearchCV(DecisionTreeRegressor(random_state = 12345), param_grid = parameters, cv = tscv, scoring = 'neg_root_mean_squared_error')
```

```
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)

# Узнаем RMSE обучающей выборки
RMSE_TRAIN = -model.best_score_
print('RMSE TRAIN:', RMSE_TRAIN)
print('TIME TRAIN [s]:', round(model.refit_time_, 3))

RMSE TRAIN: 40.244464632645034
TIME TRAIN [s]: 0.449
CPU times: total: 1min 16s
Wall time: 1min 16s
```

Проверка на тестовой выборки

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборки
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

RMSE_TEST = mean_squared_error(target_test, predictions, squared=False)
print('RMSE TEST:', RMSE_TEST)

print('Предсказание:', predictions.mean())

RMSE TEST: 0.0
Предсказание: 428.12240145743624
CPU times: total: 0 ns
Wall time: 4.97 ms

# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': 'DecisionTreeRegressor',
    'RMSE TRAIN': RMSE_TRAIN,
    'RMSE TEST': RMSE_TEST,
    'PREDICTIONS': predictions,
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.4.2.3. RandomForestRegressor

```
# Матрица гиперпараметров для случайного леса
parameters = {'bootstrap': [True], 'max_depth': [5, 15], 'max_features': ['auto', 'log2'], 'n_estimators': [25, 50]}

# Инициализируем модель с параметрами
model = GridSearchCV(RandomForestRegressor(random_state = 12345), parameters, cv = tscv, scoring = 'neg_root_mean_squared_error')
```

```
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)

# Узнаем RMSE обучающей выборки
RMSE_TRAIN = -model.best_score_
print('RMSE TRAIN:', RMSE_TRAIN)
print('TIME TRAIN [s]:', round(model.refit_time_, 3))
```

RMSE TRAIN: 48.84966377327471
TIME TRAIN [s]: 1.768
CPU times: total: 20.1 s
Wall time: 20.3 s

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборки
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

RMSE_TEST = mean_squared_error(target_test, predictions, squared=False)
print('RMSE TEST:', RMSE_TEST)

print('Предсказание:', predictions.mean())
```

RMSE TEST: 1.369625086430254
Предсказание: 428.1303578567087
CPU times: total: 15.6 ms
Wall time: 21 ms

```
# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': 'RandomForestRegressor',
    'RMSE TRAIN': RMSE_TRAIN,
    'RMSE TEST': RMSE_TEST,
    'PREDICTIONS': predictions,
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.4.2.4. LightGBMRegressor

```
# Матрица гиперпараметров для LightGBMRegressor
parameters = {'num_leaves': [5, 10],
              'learning_rate': [0.1, 0.3],
              'max_depth': [3, 5],
              'n_estimators': [10, 25]}

# Инициализируем модель с параметрами
model = GridSearchCV(LGBMRegressor(), parameters, cv = tscv, scoring = 'neg_root_mean_squared_error')
```

```
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)

# Узнаем RMSE обучающей выборки
RMSE_TRAIN = -model.best_score_
print('RMSE TRAIN:', RMSE_TRAIN)
print('TIME TRAIN [s]:', round(model.refit_time_, 3))
```

```
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Info] Auto-choosing col-wise multi-threading, the overhead of testing was 0.000748 seconds.
You can set 'force_col_wise=true' to remove the overhead.
[LightGBM] [Info] Total Bins 13807
[LightGBM] [Info] Number of data points in the train set: 2745, number of used features: 56
[LightGBM] [Info] Start training from score 378.241628
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Info] Auto-choosing col-wise multi-threading, the overhead of testing was 0.001416 seconds.
You can set 'force_col_wise=true' to remove the overhead.
[LightGBM] [Info] Total Bins 13807
[LightGBM] [Info] Number of data points in the train set: 3019, number of used features: 56
[LightGBM] [Info] Start training from score 428.122401
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
[LightGBM] [Warning] No further splits with positive gain, best gain: -inf
RMSE TRAIN: 46.596892959165395
TIME TRAIN [s]: 0.029
CPU times: total: 18.3 s
Wall time: 3.7 s
```

Проверка на тестовой выборке

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборке
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

RMSE_TEST = mean_squared_error(target_test, predictions, squared=False)
print('RMSE TEST:', RMSE_TEST)
print('Предсказание:', predictions.mean())
```

```
RMSE TEST: 3.669448040963121
Предсказание: 428.1224013715164
CPU times: total: 15.6 ms
Wall time: 7 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series({
    'NAME': 'LightGBMRegressor',
    'RMSE TRAIN': RMSE_TRAIN,
    'RMSE TEST': RMSE_TEST,
    'PREDICTIONS': predictions,
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
})

results[count_model]
count_model+=1
```

4.4.2.5. CatBoostRegressor

```
# Матрица гиперпараметров для LightGBMRegressor
parameters = {'depth' : [5, 10],
              'learning_rate' : [0.05, 0.1],
              'iterations' : [5, 10]}

# Инициализируем модель с параметрами
model = GridSearchCV(CatBoostRegressor(), parameters, cv = tscv, scoring = 'neg_root_mean_squared_error')
```

```
%%time

# Обучим модель на обучающей выборке
model.fit(features_train, target_train)

# Узнаем RMSE обучающей выборки
RMSE_TRAIN = -model.best_score_
print('RMSE TRAIN:', RMSE_TRAIN)
print('TIME TRAIN [s]:', round(model.refit_time_, 3))
```

```
6:   learn: 91.9131521      total: 943ms   remaining: 404ms
7:   learn: 83.3685064      total: 1.09s   remaining: 272ms
8:   learn: 75.7756849      total: 1.23s   remaining: 136ms
9:   learn: 69.0545274      total: 1.37s   remaining: 0us
0:   learn: 213.8050907     total: 136ms   remaining: 1.22s
1:   learn: 193.5397000     total: 270ms   remaining: 1.08s
2:   learn: 175.3163596     total: 403ms   remaining: 940ms
3:   learn: 158.9314340     total: 537ms   remaining: 805ms
4:   learn: 144.2919109     total: 670ms   remaining: 670ms
5:   learn: 130.7670811     total: 802ms   remaining: 535ms
6:   learn: 118.7487024     total: 934ms   remaining: 400ms
7:   learn: 107.6222216     total: 1.06s   remaining: 266ms
8:   learn: 97.5892652      total: 1.2s    remaining: 133ms
9:   learn: 88.7979121      total: 1.33s   remaining: 0us
RMSE TRAIN: 110.19287446107978
TIME TRAIN [s]: 1.362
CPU times: total: 4min 45s
Wall time: 46.4 s
```

Проверка на тестовой выборке

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборке
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

RMSE_TEST = mean_squared_error(target_test, predictions, squared=False)
print('RMSE TEST:', RMSE_TEST)
print('Предсказание:', predictions.mean())
```

```
RMSE TEST: 88.79791205086944
Предсказание: 427.93878430354386
CPU times: total: 15.6 ms
Wall time: 6.51 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series([
    'NAME': 'CatBoostRegressor',
    'RMSE_TRAIN': RMSE_TRAIN,
    'RMSE_TEST': RMSE_TEST,
    'PREDICTIONS': predictions,
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
])
```

```
results[count_model]
count_model+=1
```

4.4.2.6. XGBRegressor

```
# Матрица гиперпараметров для LightGBMRegressor
parameters = {"learning_rate": (0.05, 0.10),
              "max_depth": [5, 15],
              "min_child_weight": [1, 7],
              "gamma": [0.0, 0.2],
              "colsample_bytree": [0.3, 0.4],}
```

```
# Инициализируем модель с параметрами
model = GridSearchCV(xgb.XGBRegressor(), parameters, cv = tscv, scoring = 'neg_root_mean_squared_error')
```

```
%%time
```

```
# Обучим модель на обучающей выборке
model.fit(features_train, target_train)
```

```
# Узнаем RMSE обучающей выборки
RMSE_TRAIN = -model.best_score_
print('RMSE TRAIN:', RMSE_TRAIN)
print('TIME TRAIN [s]:', round(model.refit_time_, 3))
```

```
RMSE TRAIN: 42.3979935027012
TIME TRAIN [s]: 3.432
CPU times: total: 1h 23min 15s
Wall time: 8min 15s
```

Проверка на тестовой выборке

```
%%time
start_time = timeit.default_timer()
# Получим предсказания на тестовой выборке
predictions = model.predict(features_test)

elapsed = round(timeit.default_timer() - start_time, 3)

RMSE_TEST = mean_squared_error(target_test, predictions, squared=False)
print('RMSE TEST:', RMSE_TEST)
print('Предсказание:', predictions.mean())
```

```
RMSE TEST: 0.4643759627743186
Предсказание: 428.12164
CPU times: total: 250 ms
Wall time: 25 ms
```

```
# Зафиксируем результаты
results[count_model] = pd.Series([
    'NAME': 'XGBRegressor',
    'RMSE TRAIN': RMSE_TRAIN,
    'RMSE TEST': RMSE_TEST,
    'PREDICTIONS': predictions,
    'TIME TRAINING [s]': model.refit_time_,
    'TIME PREDICTION [s]': elapsed,
    'PARAMETRS': model.best_params_
])
```

```
results[count_model]
count_model+=1
```

4.4.3. Результаты

```
results = pd.DataFrame(results).T
```

```
# Смотрим на результаты
results
```

	NAME	RMSE TRAIN	RMSE TEST	PREDICTIONS	TIME TRAINING [s]	TIME PREDICTION [s]	PARAMETRS
0	LinearRegression	0.0	0.0	[214.64999999878873, 222.50500000190266, 224.5...	0.023368	0.004	{}
1	DecisionTreeRegressor	40.244465	0.0	[214.65, 222.505, 224.535, 230.86, 233.56, 233...	0.448942	0.004	{'max_depth': 21, 'min_samples_leaf': 1}
2	RandomForestRegressor	48.849664	1.369625	[211.02959999999985, 221.74363333333315, 224.6...	1.768311	0.021	{'bootstrap': True, 'max_depth': 15, 'max_feat...
3	LightGBMRegressor	46.596893	3.669448	[212.60750201912327, 225.2029045836576, 225.20...	0.029	0.006	{'learning_rate': 0.3, 'max_depth': 5, 'n_esti...
4	CatBoostRegressor	110.192874	88.797912	[273.7651383695252, 273.7651383695252, 273.765...	1.361949	0.006	{'depth': 10, 'iterations': 10, 'learning_rate...
5	XGBRegressor	42.397994	0.464376	[213.17856, 223.10542, 224.70964, 231.35298, 2...	3.432141	0.023	{'colsample_bytree': 0.4, 'gamma': 0.0, 'learn...

```
# Рассчитываем рейтинг с учетом указанных приоритетов
results['RATING'] = (
    0.5 * (1 - (results['RMSE TEST'] / results['RMSE TEST'].max())) +
    0.3 * (1 - (results['TIME TRAINING [s]'] / results['TIME TRAINING [s]'].max())) +
    0.2 * (1 - (results['TIME PREDICTION [s]'] / results['TIME PREDICTION [s]'].max()))
)
```

```
# Сортируем DataFrame по убыванию рейтинга
results = results.sort_values(by='RATING', ascending=False)
```

	NAME	RMSE TRAIN	RMSE TEST	PREDICTIONS	TIME TRAINING [s]	TIME PREDICTION [s]	PARAMETRS	RATING
0	LinearRegression	0.0	0.0	[214.64999999878873, 222.50500000190266, 224.5...	0.023368	0.004	{}	0.963175
1	DecisionTreeRegressor	40.244465	0.0	[214.65, 222.505, 224.535, 230.86, 233.56, 233...	0.448942	0.004	{'max_depth': 21, 'min_samples_leaf': 1}	0.925976
3	LightGBMRegressor	46.596893	3.669448	[212.60750201912327, 225.2029045836576, 225.20...	0.029	0.006	{'learning_rate': 0.3, 'max_depth': 5, 'n_esti...	0.924629
2	RandomForestRegressor	48.849664	1.369625	[211.02959999999985, 221.74363333333315, 224.6...	1.768311	0.021	{'bootstrap': True, 'max_depth': 15, 'max_feat...	0.655113
5	XGBRegressor	42.397994	0.464376	[213.17856, 223.10542, 224.70964, 231.35298, 2...	3.432141	0.023	{'colsample_bytree': 0.4, 'gamma': 0.0, 'learn...	0.497385
4	CatBoostRegressor	110.192874	88.797912	[273.7651383695252, 273.7651383695252, 273.765...	1.361949	0.006	{'depth': 10, 'iterations': 10, 'learning_rate...	0.32878

Создадим отдельный датасет, в котором будет храниться реальное значение и предсказания модели.

```
info_result = pd.DataFrame(index=target_test.index)
info_result['REAL'] = target_test
for i, name_model in enumerate(results['NAME']):
    info_result[name_model] = results['PREDICTIONS'][i]
info_result.head()
```

	REAL	LinearRegression	DecisionTreeRegressor	LightGBMRegressor	RandomForestRegressor	XGBRegressor	CatBoostRegressor
date							
2006-01-03	214.650	214.650	214.650	211.029600	212.607502	273.765138	213.178558
2006-01-04	222.505	222.505	222.505	221.743633	225.202905	273.765138	223.105423
2006-01-05	224.535	224.535	224.535	224.632500	225.202905	273.765138	224.709641
2006-01-06	230.860	230.860	230.860	229.763514	231.564346	281.937215	231.352982
2006-01-09	233.560	233.560	233.560	232.649071	233.394142	281.937215	233.538986

Сразу все данные в одном графике нежелательно уложиться, т.к. не очень информативно, поэтому разобьем на несколько блоков.

```

fig, ax = plt.subplots(6, figsize=(20, 45))


for i in range(0, len(info_result.columns) - 1):
    ax[i].plot(info_result['REAL'], alpha=0.7, color='red', lw=2.5)
    ax[i].plot(info_result[info_result.columns[i+1]], alpha=0.7, color='blue', lw=2.5)
    ax[i].legend([info_result.columns[0], info_result.columns[i+1]], fontsize='xx-large')
    ax[i].grid()

    ax[i].set_xlabel('Временной ряд', fontsize=20)
    ax[i].set_ylabel('Значение RMSE', fontsize=20)
    ax[i].set_title(f'Гистограмма предсказанной модели {info_result.columns[i+1]} и реального значения', fontsize=20)

plt.show()

```





Предсказания модели в некотором степени отличаются от реальных значений.

4.5. Вывод машинного обучения

Лучшие модели - LightGBMRegressor и Linear Regression, с низкой ошибкой RMSE и быстрым временем обучения и предсказания. RandomForestRegressor и XGBRegressor также показывают хорошие результаты, но требуют больше времени на обучение. DecisionTreeRegressor имеет нулевую ошибку на обучающем наборе, что может указывать на переобучение. CatBoostRegressor показывает наихудшие результаты.

5. Вывод

В ходе лабораторной работы изучили основные методы анализа и прогнозирования временных рядов.